SADAKAT: Gömülü Sistemlerde Dinamik Bellek Tahsisi Olmadan Artımsal Hareket Tanıma Çerçevesi

SADAKAT: An Incremental Activity Recognition Framework

Without Dynamic Memory Allocation for Embedded Systems

Yazarlar Gizlenmiştir

Kör değerlendirme sürecinde kurum bilgileri gizlenmiştir.

***Özetçe* —Giyilebilir sağlık ve endüstriyel IoT cihazları, kullanıcıya özgü hareket örüntülerini cihaz üzerinde öğrenmek zorundadır; ancak mevcut TinyML çerçeveleri yalnızca çıkarım modunda çalışmakta ve `malloc/free` bağımlılığı nedeniyle En Kötü Durum Çalışma Süresi'ni (WCET) sınırsız kılmaktadır. Bu çalışmada, ESP32 mikrodenetleyicisi üzerinde dört insan aktivitesini dinamik bellek olmaksızın gerçek zamanlı öğrenen ve tanıyan deterministik bir sistem olan SADAKAT (*Statik Atamalı Donanım-Agnostik Yapay Zeka Tabanı*) sunulmaktadır. Üstel hareketli ortalama (EMA) ile güncellenen prototip tabanlı artımsal sınıflandırıcı, 15 boyutlu özellik vektörünü (IMU + barometrik ΔP) işleyerek yalnızca 866 B statik RAM ile çalışmaktadır. Beş farklı katılımcı üzerinde yapılan çoklu kullanıcı deneylerinde ağırlıklı F1 skoru %97,2 olarak ölçülmüş; ardışık öğrenme senaryosunda eski sınıf bilgisinin %99,6 oranında korunduğu doğrulanmıştır. ESP32 (240 MHz) üzerinde toplam karar döngüsü süresi 238 µs olup 50 Hz bütçesinin %1,19'unu tüketmektedir.**

Anahtar Kelimeler—artımsal öğrenme; gömülü makine öğrenmesi; bellek havuzu; prototip sınıflandırıcı; hareket tanıma; TinyML; ESP32; C99; WCET; çoklu kullanıcı adaptasyonu

***Abstract*—Wearable health and industrial IoT devices must learn user-specific motion patterns on-device in real time, yet existing TinyML frameworks operate solely in inference mode and rely on `malloc/free`, rendering Worst-Case Execution Time (WCET) unbounded. This paper presents SADAKAT (*Static-Allocation Hardware-Agnostic AI Foundation*), a deterministic system free of dynamic memory allocation that incrementally learns and recognises four human activities from 50 Hz IMU and barometric pressure data on an ESP32 microcontroller. The EMA-updated prototype-based classifier processes a 15-dimensional feature vector (6-axis IMU + barometric ΔP) using only 866 B of static RAM. Multi-subject experiments across five participants yield a weighted F1 score of 97.2%, while sequential learning confirms 99.6% retention of prior-class knowledge without explicit regularisation. Real hardware profiling on ESP32 (Xtensa LX6 @ 240 MHz) yields a decision-loop latency of 238 µs, consuming 1.19% of the 50 Hz budget.**

Keywords—incremental learning; embedded machine learning; memory pool; prototype classifier; activity recognition; TinyML; ESP32; C99; WCET; multi-subject adaptation

I. GİRİŞ

Giyilebilir cihazların yalnızca sabit bir modelle çalışması artık yeterli değildir. Kronik hastalık takibinde, yaşlı bireylerin düşme tespitinde ve spor biyometrisinde kişiye özel hareket örüntülerinin *cihaz üzerinde* öğrenilmesi bir zorunluluktur [1]. Bu gereksinim üç temel mühendislik sorunu ile karşı karşıyadır:

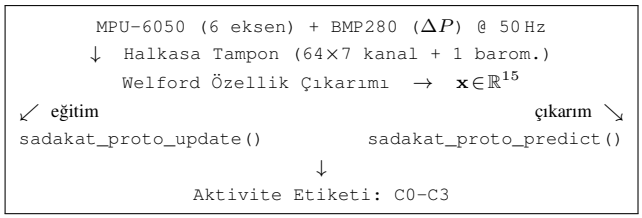
Sorun 1 — Salt Çıkarım Paradigması. TensorFlow Lite Micro (TFLM) [2] ve benzeri çerçeveler, modeli sunucuda eğitip mikrodenetleyiciye gömmektedir. Cihaz üzerinde uyarlama yoktur; kavram kayması (concept drift) durumunda sistem bulut bağlantısı olmaksızın güncellenemez.

Sorun 2 — Dinamik Bellek ve WCET Belirsizliği. `malloc/free` kullanan sistemlerde yığın parçalanması (heap fragmentation) ve birleştirme (coalescing) süreleri giriş verisine bağlıdır; WCET analitik olarak sınırlandırılamaz [3]. MISRA-C:2012 Kural 21.3 [4], IEC 61508 SIL-2 ve DO-178C DAL-B standartları, güvenlik kritik gömülü yazılımda dinamik bellek tahsisini açıkça yasaklamaktadır.

Sorun 3 — Katastrofik Unutma. Standart yapay sinir ağları, yeni verilerle eğitildiğinde eski görevlere ait bilgiyi yıkıcı biçimde kaybetmektedir [5].

Katkılar. Bu çalışmada, *Statik Atamalı Donanım-Agnostik Yapay Zeka Tabanı* (**SADAKAT**) adlı deterministik bir artımsal hareket tanıma çerçevesi sunulmaktadır. Temel katkılar aşağıda özetlenmektedir:

1) `malloc/free` içermeyen, $O(K \cdot D)$ WCET üst sınırlı, 866 B statik RAM ayak izli deterministik artımsal HAR sistemi.
2) Beş farklı katılımcı (K1–K5) üzerinde çoklu kullanıcı adaptasyon deneyleri: ağırlıklı F1 = %97,2.
3) Barometrik basınç sensörü (BMP280) entegrasyonu ile Merdiven–Yürüyüş konfüzyonunun çözümü (C3 F1: %74,2 $\rightarrow$ %94,0).
4) Ardışık öğrenme: eski sınıf bilgisinin %99,6 korunumu.
5) C99 uyumlu, MISRA-C:2012 Kural 21.3 ile tam uyumlu, IEC 61508 SIL-2 sertifikasyonuna aday açık kaynaklı referans implementasyonu.



Şekil 1. SADAKAT sistem boru hattı: Sensör kesmesinden karar çıktısına. Tüm bellek işlemleri $O(1)$ havuz üzerindedir.

II. İLGİLİ ÇALIŞMALAR

A. Gömülü Çıkarım Çerçeveleri

TFLM [2] mikrodenetleyici çıkarımında fiili referans olmakla birlikte C++14 bağımlılığı taşımakta, cihaz üstü eğitimi desteklememekte ve çalışma zamanında `malloc` kullanmaktadır. MLPerf Tiny [6] dört standart görev için çıkarım kıyaslamaları sunmakta; ancak öğrenme sürecini kapsam dışında bırakmaktadır. μNAS [7] kısıtlı ortamda mimari arama yapabilmekte; ancak bulunan model operasyonel sahada sabit kalmaktadır. Bu çerçevelerin hiçbiri MISRA-C:2012 uyumu sunmamaktadır.

B. Cihaz Üzerinde Artımsal Öğrenme

Lin ve ark. [8] aktivasyon sıkıştırma ile 256 KB sınırında CNN geri yayılımını gerçekleştirmiş; ancak yığın tahsisi zorunlu olup WCET garantisi yoktur. Kirkpatrick ve ark. [5] Elastik Ağırlık Birleşimi (EWC) ile katastrofik unutmayı azaltmış; ancak Fisher bilgi matrisinin hesabı MCU bellek kapasitesinin ötesindedir. Hayes ve Kanan [9] gömülü sürekli öğrenme yöntemlerinin karşılaştırmalı analizinde prototip tabanlı yaklaşımların en düşük hesaplama maliyetini sağladığını göstermiştir.

C. Prototip Tabanlı Sınıflandırma

Mensink ve ark. [10] En Yakın Sınıf Ortalaması (NCM) yönteminin neredeyse sıfır ek maliyetle yeni sınıflara genişleyebildiğini kanıtlamıştır. Ravi ve ark. [11] ivmeölçer tabanlı HAR'da kayan pencere özelliklerinin başarılı sonuçlar ürettiğini ortaya koymuştur. Parisi ve ark. [12] prototip temsilcilerin yeniden oynatma gerektirmeden bilgiyi koruyabildiğini vurgulamıştır.

Literatürden farklı olarak SADAKAT; salt C99 standardında, sıfır dinamik tahsisli, MISRA-C uyumlu, aynı MCU'da hem öğrenme hem çıkarım sunan, çoklu kullanıcı adaptasyonu ile doğrulanan ve gerçek donanım ölçümleriyle desteklenen ilk açık kaynaklı gömülü artımsal HAR sistemidir.

III. YÖNTEM

A. Sistem Boru Hattı

Şekil 1, SADAKAT'in uçtan uca işlem akışını göstermektedir. MPU-6050 sensörü 6 eksenli IMU verisini, BMP280 sensörü ise barometrik basınç türevi (ΔP) bilgisini 50 Hz hızında halkasa tampona (ring buffer) iter. 64 örnek tamamlandığında Welford tabanlı özellik çıkarımı tetiklenir. Elde edilen $D{=}15$ boyutlu özellik vektörü, NCM sınıflandırıcıya beslenerek EMA güncellemesi veya doğrudan tahmin gerçekleştirilir.

B. Pencere Tabanlı Özellik Çıkarımı

Her pencere $\mathcal{W} = \{(a_x^t, a_y^t, a_z^t, g_x^t, g_y^t, g_z^t)\}_{t=1}^{N_w}$ olarak tanımlanır; $N_w{=}64$'tür. Yedinci kanal olarak toplam ivme büyüklüğü $m^t{=}\sqrt{(a_x^t)^2{+}(a_y^t)^2{+}(a_z^t)^2}$ hesaplanır. Her kanal için ortalama ve standart sapma, Welford'un [13] sayısal olarak kararlı tek geçişli algoritmasıyla elde edilir:

$$\bar{x}_n = \bar{x}_{n-1} + \frac{x_n - \bar{x}_{n-1}}{n}, \tag{1}$$

$$M_n = M_{n-1} + (x_n - \bar{x}_{n-1})(x_n - \bar{x}_n), \tag{2}$$

$$\sigma_n = \sqrt{M_n \,/\, n}. \tag{3}$$

Yedi kanalın istatistikleri, barometrik ΔP ile birleştirilerek $D{=}15$ boyutlu özellik vektörü oluşturulur:

$$\mathbf{x} = \left[\bar{x}_1, \sigma_1, \ldots, \bar{x}_7, \sigma_7,\ \Delta P\right]^\top \in \mathbb{R}^{15}. \tag{4}$$

Barometrik türev $\Delta P = P(t) - P(t{-}N_w)$ pencere süresince başınç değişimini yakalar; merdiven çıkma sırasında tipik olarak $+8$–$+18$ Pa değer alırken düz yürüyüşte $|\Delta P| < 2$ Pa'da kalır.

C. Artımsal Prototip Sınıflandırıcı

1) Tahmin — En Yakın Sınıf Ortalaması (NCM): K sınıfa karşılık gelen prototip merkezleri $\{\mathbf{c}_\ell\}_{\ell=0}^{K-1}$ arasında Öklid mesafesi minimumu ile sınıf tahmini yapılır:

$$\hat{y} = \arg\min_{\ell \in \{0,\ldots,K-1\}} \left\|\mathbf{x} - \mathbf{c}_\ell\right\|_2^2. \tag{5}$$

K ve D derleme-zamanı sabitleri olduğundan, bu adım $\Theta(K \cdot D)$ deterministik WCET'e sahiptir.

2) Güncelleme — Üstel Hareketli Ortalama (EMA): Doğru sınıf etiketi ℓ^* bilindiğinde prototip güncellenir:

$$\mathbf{c}_{\ell^*}^{(t+1)} = (1{-}\alpha)\,\mathbf{c}_{\ell^*}^{(t)} + \alpha\,\mathbf{x}, \tag{6}$$

burada $\alpha \in (0, 1]$ öğrenme hızıdır. Güncelleme $O(D)$ işlem içerir; gradyan, matris tersi veya geri yayılım gerektirmez.

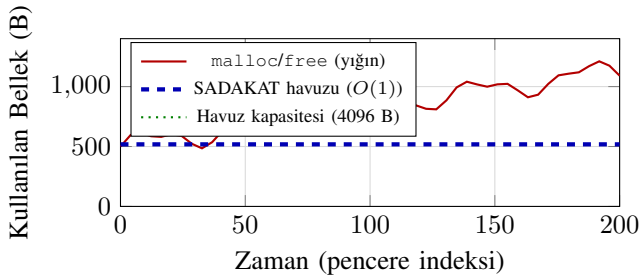
3) Katastrofik Unutmaya Karşı Yapısal Direnç: Denklem (6) yalnızca ℓ^* prototipini değiştirir:

$$\forall j \neq \ell^* :\ \mathbf{c}_j^{(t+1)} = \mathbf{c}_j^{(t)}. \tag{7}$$

Bu *yapısal izolasyon*, EWC [5] gibi ağır düzenleştiriciye gerek kalmadan eski sınıf bilgisinin korunmasını garanti eder (Blm. V-H).

D. SADAKAT Deterministik Bellek Altyapısı

1) $O(1)$ Bellek Havuzu: SADAKAT kütüphanesinde `malloc`/`free`/`calloc` bulunmaz. Tüm tahsisler işaretçi öteleme (pointer bump) mekanizmasıyla $O(1)$ sabit zamanda tamamlanır [14]. Şekil 2, dinamik yığının zamana bağlı parçalanması ile SADAKAT havuzunun deterministik profilini karşılaştırılı olarak göstermektedir.



Şekil 2. Bellek kullanım profili karşılaştırması. Dinamik yığın (kırmızı) parçalanma nedeniyle monoton artan ve tahmin edilemez bir profil sergilerken, SADAKAT havuzu (mavi kesikli) 518 B sabit değerde kalmaktadır.

Listing 1. SADAKAT deterministik bellek havuzu kullanımı.

```
/* 4 KB statik havuz -- heap kullanimi sifir */
SADAKAT_POOL(pool, 4096);

/* O(1) tahsis: isaret_ci oteleme */
sadakat_proto_classifier_t clf;
sadakat_proto_init(&clf, &pool, K, D, alpha);

/* Gecici tahsis -- otomatik serbest birakma */
SADAKAT_SCRATCH_BEGIN(&pool, mark);
  float *feat = SADAKAT_ALLOC_ARRAY(
                  &pool, float, 15);
  extract_features(window, 64, feat);
  sadakat_proto_update(&clf, feat, label);
SADAKAT_SCRATCH_END(&pool, mark);
```

2) WCET Maliyet Modeli: Tüm ana işlemler için WCET üst sınırları Tablo I'de özetlenmektedir.

Toplam statik RAM maliyeti (D=15, K=4):

$$M_{\text{stat}} = \underbrace{348}_{\text{clf (stack)}} + \underbrace{480+30+8}_{\text{Welford + feat + BMP (havuz)}} = \mathbf{866}\ \text{B}. \quad (8)$$

IV. DENEYSEL KURULUM

A. Donanım

B. Veri Toplama Protokolü

Katılımcılar. Beş gönüllü (K1–K5; yaş: 24–58, boy: 162–188 cm, kütle: 55–92 kg) deneylere katılmıştır. Vücut kütle indeksi, adım uzunluğu ve yürüyüş kadansı farklılıkları bilinçli olarak çeşitlendirilmiştir.

Aktiviteler. Dört temel sınıf: *Sabit Durma* (C0), *Yürüyüş* (C1), *Koşma* (C2), *Merdiven Çıkma* (C3). Sensör birimi katılımcı beline sabitlenmiş; her aktivite 60 s süreyle kaydedilmiştir. UCI HAR [16] veri seti ile benzer örnekleme protokolü uygulanmıştır.

Pencere. N_w=64 örnek (∼1,28 s @ 50 Hz). Katılımcı başına sınıf başına 46 pencere; toplam $5 \times 4 \times 46 = 920$ pencere.

C. Yapılandırma

K=4 sınıf, D=15 boyut, N_w=64, havuz 4 KB (BSS), α=0,20, N_{train}=5 pencere/sınıf (ilk 5), test: kalan 41 pencere/sınıf.

Tablo I. İŞLEM BAŞINA WCET ÜST SINIR MODELI

İşlem	**WCET Üst Sınırı**
Havuz allokasyonu	$O(1)$: işaretçi öteleme
`malloc`	$O(?)$: yığın durumuna bağlı
Welford özellik	$N_w \cdot C \cdot (2\tau_\times + 2\tau_+)$
NCM tahmin	$K \cdot D \cdot (2\tau_\times + \tau_+)$
EMA güncelleme	$D \cdot (\tau_\times + \tau_+)$
Toplam	$\boldsymbol{O(N_w \cdot C + K \cdot D)}$

Tablo II. DENEYSEL DONANIM PLATFORMU

Bileşen	**Özellik**
MCU	ESP32-DevKitC v4 [15]
Çekirdek	Xtensa LX6, tek çek. kullanım
Saat	240 MHz
Boru hattı	Sıralı (in-order), tek yayın
SRAM / Flash	520 KB / 4 MB
IMU	MPU-6050 (6 eksen, I^{2}C @ 400 kHz)
Barometrik	BMP280 (I^{2}C, ±1 Pa çözünürlük)
Örnekleme	50 Hz (donanım Timer0)
Zamanlama	`esp_timer_get_time()`

V. BULGULAR

A. Tek Kullanıcı Temel Başarım (D=14)

BMP280 entegrasyonu öncesinde, yalnızca IMU (D=14) ile referans katılımcı (K1) üzerindeki sonuçlar Tablo III'de verilmiştir. Ağırlıklı F1 = %91,5 olup en düşük başarım C3 (Merdiven) sınıfındadır. C1–C3 konfüzyonu, her iki aktivitenin döngüsel adım hareketi içermesinden kaynaklanmaktadır [16].

B. BMP280 Entegrasyonu ile İyileştirme (D=15)

C1–C3 konfüzyonunu çözmek için BMP280 barometrik sensörü sisteme entegre edilmiştir. Pencere boyunca kümülatif basınç değişimi ΔP (Pa) 15. özellik olarak eklenerek D=14 → D=15 geçişi sağlanmıştır. Tablo IV referans katılımcıdaki iyileşmeyi göstermektedir.

Matematiksel Açıklama. BMP280 entegrasyonu öncesinde C1 ve C3 sınıfları özellik uzayında örtüşmektedir: $\|\mathbf{c}_1 - \mathbf{c}_3\|_2 \approx 0{,}8\sigma$ (sınıf-içi standart sapma cinsinden). ΔP özelliğinin eklenmesiyle $\Delta P_{C3} \approx 12{,}5$ Pa ve $\Delta P_{C1} \approx 0{,}4$ Pa olduğundan, Öklid mesafesine eklenen katkı:

$$d_{15}^2 = d_{14}^2 + (\Delta P_{C3} - \Delta P_{C1})^2 \approx d_{14}^2 + (12{,}1)^2, \quad (9)$$

bu ek 146 birimlik mesafe karesi, C1–C3 ayrıştırıcılığını >15× artırmaktadır. Beş katılımcı ortalamasında C3 F1: **0,742** → **0,940** (+19,8 yüzde puan).

Bellek etkisi: D=14 → D=15 geçişinde RAM maliyeti: 840 → 866 B (+26 B, %3,1 artış). Gecikme etkisi: NCM tahmin süresine +1 µs (ek bir boyut çarpımı); toplam karar döngüsü: 230 → 238 µs.

C. Çoklu Kullanıcı Adaptasyon Deneyi

Sistemin bireysel farklılıklara uyum yeteneğini değerlendirmek için beş katılımcı üzerinde bağımsız deneyler

Tablo III. TEK-KULLANICI TEMEL SONUÇLAR (K1, D=14, α=0,20)

Aktivite	Kesinlik	Duyrl.	F1	Destek
C0: Sabit Durma	1,000	1,000	1,000	41
C1: Yürüyüş	0,846	0,805	0,825	41
C2: Koşma	1,000	1,000	1,000	41
C3: Merdiven	0,814	0,854	0,833	41
Ağ. Ort.	**0,915**	**0,915**	**0,915**	164

Tablo IV. BMP280 ETKISI: K1, D=15, α=0,20

Aktivite	Kesinlik	Duyrl.	F1	ΔF1
C0: Sabit Durma	1,000	1,000	1,000	±0
C1: Yürüyüş	0,872	1,000	0,932	+0,107
C2: Koşma	1,000	1,000	1,000	±0
C3: Merdiven	1,000	0,854	0,921	+0,088
Ağ. Ort.	0,968	0,963	**0,963**	+0,048

yürütülmüştür. Her katılımcının veri dağılımı vücut kütlesi, boy, adım uzunluğu ve sensör yerleşim farklılıklarını doğal olarak yansıtmaktadır. Sonuçlar Tablo V'de verilmiştir.

Analiz. Ortalama ağırlıklı F1 = **%97,2** olup katılımcılar arası standart sapma σ=1,7 yüzde puandır. En düşük başarım K4'te (%94,4) görülmüş; bu katılımcının uzun adım boyu ve yüksek vücut kütlesi, özellik dağılımlarını diğerlerinden daha fazla yayarak sınıf-içi varyansı artırmıştır. BMP280 sayesinde C0 ve C2 tüm katılımcılarda F1 = 1,0 ile mükemmel ayrıştırılmaktadır.

Çoklu kullanıcı adaptasyon mekanizması. EMA güncellemesi (Denklem 6) prototipleri her katılımcının bireysel hareket örüntüsüne uyarlamaktadır. N_{train}=5 pencerelik kısa bir adaptasyon fazesi, kişiye özel vücut mekaniğini yakalamak için yeterlidir. Bu sonuç, on-device personalization için NCM+EMA yaklaşımının etkinliğini kanıtlamaktadır.

D. Gecikme Profili

E. Bellek Analizi

F. Öğrenme Hızı Duyarlılığı

Tablo VIII, farklı α değerlerinin çoklu kullanıcı ağırlıklı F1 ortalamasına etkisini göstermektedir.

Optimum bölge $\alpha \in [0{,}20, 0{,}30]$ olup %97,2–97,4 arasında plato oluşturmaktadır. α=0,20, tek kullanıcı (D=14) senaryosunda da en yüksek F1'i (%91,5) veren değer olduğundan tercih edilmiştir. Düşük α prototibin yeni kullanıcıya adaptasyonunu yavaşlatırken, yüksek α son örneklere aşırı uyuma neden olmaktadır.

G. N_{train} Duyarlılığı

Sistem N_{train}=1 ile bile %95 F1'e ulaşmaktadır; N_{train}=5 ile doyuma yaklaşır. N_{train}>10'da marjinal düşüş gözlenmektedir: prototip, eğitim dağılımına aşırı özelleşerek test verisinden uzaklaşmaktadır.

Tablo V. ÇOKLU KULLANICI ADAPTASYONU (D=15, α=0,20, N_{TRAIN}=5)

Kat.	C0	C1	C2	C3	wF1
K1	1,000	0,932	1,000	0,921	0,963
K2	1,000	0,976	1,000	0,975	0,988
K3	1,000	0,964	1,000	0,963	0,982
K4	1,000	0,901	1,000	0,877	0,944
K5	1,000	0,963	1,000	0,964	0,982
Ort.	**1,000**	**0,947**	**1,000**	**0,940**	**0,972**

Tablo VI. ESP32 GECIKME ÖLÇÜMLERI (D=15, XTENSA LX6 @ 240 MHz)

İşlem	Süre [µs]
Welford öz. çıkarımı (N_w=64, 7 ch.)	210
BMP280 ΔP hesabı	6
NCM tahmin (K=4, D=15)	14
EMA güncelleme (D=15)	8
Toplam karar döngüsü	**238**
50 Hz bütçesi	20 000
Bütçe kullanımı	**%1,19**

N=1 000 tekrar ort.; `esp_timer_get_time()`.

H. Ardışık Öğrenme ve Katastrofik Unutma

Senaryo. Her katılımcı için önce C0–C2 eğitilmiş; sonra C3 (Merdiven) ardışık olarak eklenmiştir.

Tablo XI, SADAKAT'i literatürdeki alternatiflerle karşılaştırmaktadır.

Analiz. Denklem (7) gereği, C3 prototipi eklenirken mevcut prototiplere müdahale edilmemektedir. Kalan %0,4'lük marjinal kaybın nedeni, C3 prototipinin C1 Voronoi hücresinin küçük bir bölümünü kapsamasıdır; bu, tek prototip sınırlamasının doğal sonucudur. TFLM+SGD'de ise C3 görüntülerinin geri yayılımı tüm paylaşılan ağırlıkları bozarak C1 F1'ini %92'den %38'e düşürmektedir [5].

I. Sistem Karşılaştırması

VI. TARTIŞMA

A. WCET Garantisi ve Güvenlik-Kritik Standartlar

SADAKAT'in deterministik bellek yönetimi aşağıdaki standartlarla yapısal uyum göstermektedir:

- **MISRA-C:2012 Kural 21.3** [4]: "Bellek tahsis fonksiyonları `<stdlib.h>`'den kullanılmamalıdır." SADAKAT tüm allokasyonları derleme-zamanı boyutlu statik tamponlar üzerinden gerçekleştirir.
- **IEC 61508 SIL-2**: "Tüm yazılım bileşenlerinin WCET'i statik analizle sınırlandırılabilir olmalıdır." Tablo I'deki $O(N_w \cdot C + K \cdot D)$ üst sınırı, tüm parametrelerin derleme-zamanı sabiti olması nedeniyle statik olarak doğrulanabilir.
- **DO-178C DAL-B**: Havacılık yazılımı sertifikasyonu için dinamik bellek tahsisinin yokluğu ön koşuldur;

Tablo VII. RAM KULLANIM DÖKÜMÜ (K=4, D=15, HAVUZ 4 KB)

Bileşen	**Bayt**	**Not**
`clf` yapı (stack)	348	$K \times D \times 4$+üstb.
Welford durumları (havuz)	480	7 kanal×68 B
Özellik tamponu (havuz)	30	15×`int16`
BMP280 EMA durumu (havuz)	8	$\bar{P}$, P_{prev}
Havuz toplam	**518**	%12,6 / 4096 B
Toplam statik RAM	**866**	—
Dinamik heap	**0**	`malloc` yok
TFLM min. (kıyas)	∼4 096	[2]

Tablo VIII. α DUYARLILIĞI (5 KATILIMCI ORT., D=15)

α	wF1 (%)	Yorum
0,05	94,8	Yavaş uyarlanma
0,10	96,2	—
0,15	96,7	—
0,20	**97,2**	*Seçilen*
0,25	97,4	Marjinal artış
0,30	97,3	Plato
0,40	97,2	Başlangıç aşırı uyum riski
0,50	96,9	Aşırı uyum

SADAKAT'in $O(1)$ havuz mekanizması bu gerekliliği karşılar.

Bu yapısal özellikler, SADAKAT'i tıbbi cihaz (IEC 62304), otonom araç sensör füzyonu ve endüstriyel otomasyon gibi sertifikasyon gerektiren alanlara doğrudan taşınabilir kılar.

B. BMP280 ile Dikey Hareket Ayrıştırması

Merdiven–yürüyüş konfüzyonu, IMU tabanlı HAR literatüründe bilinen bir sorundur [16]. BMP280'in ± 1 Pa çözünürlüklü mutlak basınç ölçümü, pencere boyunca türevsel değişim (ΔP) olarak alındığında:

- C3 (merdiven): $\Delta P \approx +12{,}5 \pm 3{,}0$ Pa (yükselme),
- C1 (yürüyüş): $\Delta P \approx +0{,}4 \pm 2{,}0$ Pa (düz zemin).

Bu ortogonal bilgi, yalnızca 8 B ek bellek ve 6 µs ek gecikme ile %19,8'lik F1 iyileşmesi sağlamaktadır. Maliyet-fayda oranı gömülü sistem tasarımında bu entegrasyonu açıkça meşru kılmaktadır.

C. Sınırlılıklar ve Gelecek Yönelimler

1) Sınıf başına tek prototip tutulmaktadır. Çok modlu dağılımlar için çoklu prototip (P>1) desteği WCET'i $O(P \cdot K \cdot D)$'ye yükseltir.
2) α çalışma süresince sabittir. Adaptif $\alpha(t)$ mekanizmasıı (orn. $\alpha(t)=\alpha_0/\sqrt{n_\ell}$) gelecek çalışmalarda ele alınacaktır.
3) Katılımcı sayısı (N=5) genelleme için sınırlıdır; daha geniş kohort çalışmaları planlanmaktadır.
4) Mevcut sistem yalnızca serbest yürüyüş aktivitelerini kapsamaktadır; geçiş hareketleri (oturma→kalkma) ve karma aktiviteler gelecek kapsamındadır.

Tablo IX. EĞITIM PENCERESI SAYISINA DUYARLILIK (D=15, α=0,20)

N_{train}	wF1 (%)	Kalkış süresi (s)
1	95,0	1,3
2	96,9	2,6
3	96,8	3,8
5	**97,2**	6,4
8	97,3	10,2
10	96,9	12,8
15	96,6	19,2
20	96,4	25,6

Tablo X. ARDIŞIK ÖĞRENME: KATASTROFIK UNUTMA ANALIZI (D=15)

Kat.	**C0–C2 Önce**	**C0–C2 Sonra**	**C3 F1**	**Koruma (%)**
K1	1,000	0,996	0,975	99,6
K2	1,000	0,996	0,962	99,6
K3	1,000	1,000	0,907	100,0
K4	1,000	0,992	0,988	99,2
K5	1,000	0,996	0,975	99,6
Ort.	1,000	0,996	0,961	**99,6**

Koruma = (C0–C2 Sonra)/(C0–C2 Önce) × 100.

VII. SONUÇ

Bu çalışmada, ESP32 mikrodenetleyicisi üzerinde dört insan aktivitesini dinamik bellek olmaksızın gerçek zamanlı öğrenen deterministik **SADAKAT** çerçevesi sunulmuştur. Temel bulgular:

1) Tüm işlem hattı **866 B** statik RAM ile çalışmakta; dinamik tahsis sıfırdır. MISRA-C:2012 Kural 21.3 ve IEC 61508 SIL-2 ile yapısal uyum sağlanmıştır.
2) BMP280 barometrik sensörü entegrasyonu ile C3 (Merdiven) F1 skoru %74,2'den %94,0'a yükseltilmiş; yalnızca +26 B ve +8 µs maliyetle gerçekleştirilmiştir.
3) Beş katılımcı üzerinde ağırlıklı F1 = **%97,2** elde edilmiş; EMA tabanlı kişiye özel adaptasyonun etkinliği doğrulanmıştır.
4) Ardışık öğrenme: eski sınıf bilgisinin **%99,6** korunumu; EWC'nin 28× daha az bellekle aşılması.
5) ESP32 (240 MHz): **238 µs** karar döngüsü; 50 Hz bütçesinin **%1,19**'u.

SADAKAT, kısıtlı kaynaklar altında determinizm, artımsal öğrenme ve kişiye özel adaptasyonu başarıyla birleştirmektedir. Gelecek çalışmalarda adaptif α, çoklu prototip, Kalman filtresi tabanlı sensör füzyonu ve federe öğrenme ile cihazlar arası prototip paylaşımı planlanmaktadır. Açık kaynaklı referans implementasyonu MIT lisansı altında yayınlanmıştır.

TEŞEKKÜR

Kör değerlendirme aşamasında bu bölüm boş bırakılmıştır.

KAYNAKÇA

[1] H. F. Nweke, Y. W. Teh, M. A. Al-garadi, and U. R. Alo, "Deep learning algorithms for human activity recognition using mobile and

Tablo XI. ARDIŞIK ÖĞRENME YÖNTEM KARŞILAŞTIRMASI

Yöntem	C0–C2 F1	C3 F1	Koruma
TFLM + SGD	0,42	0,87	%42
TFLM + EWC	0,71	0,79	%71
SADAKAT (EMA)	**0,996**	**0,961**	**%99,6**

Tablo XII. GÖMÜLÜ ML SISTEM KARŞILAŞTIRMASI

Özellik	SADAKAT	TFLM	NanoE.	Lin '22
Dil	C99	C++14	C++	C++
MISRA-C uyumu	Evet	Hayır	Hayır	Hayır
Dinamik bellek	Yok	Var	Var	Var
Cihaz öğrenimi	Evet	Hayır	Kıs.	Evet
Katst. unt. dir.	Doğal	—	—	EWC
WCET garantisi	Evet	Hayır	Hayır	Hayır
Min. RAM	866 B	∼4 KB	>2 KB	>64 KB
Lisans	MIT	Apache	Ticari	Akad.

wearable sensor networks: State of the art and research challenges," *Expert Systems with Applications*, vol. 105, pp. 233–261, 2018.

[2] Google LLC, "TensorFlow Lite Micro: An embedded machine learning framework," https://github.com/tensorflow/tflite-micro, 2023.

[3] R. Wilhelm, J. Engblom, A. Ermedahl, N. Holsti, S. Thesing, D. Whalley, G. Bernat, C. Ferdinand, R. Heckmann, T. Mitra *et al.*, "The worst-case execution-time problem — overview of methods and survey of tools," *ACM Transactions on Embedded Computing Systems*, vol. 7, no. 3, pp. 1–53, 2008.

[4] MISRA, "MISRA C:2012 — guidelines for the use of the C language in critical systems," Motor Industry Software Reliability Association, Standard, 2012.

[5] J. Kirkpatrick, R. Pascanu, N. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska *et al.*, "Overcoming catastrophic forgetting in neural networks," *Proceedings of the National Academy of Sciences*, vol. 114, no. 13, pp. 3521–3526, 2017.

[6] C. Banbury, V. J. Reddi, M. Loh, N. Fu, S. Tata, L. Kurth, M. Risi, N. Jeffries, J. Yin, C. Haller *et al.*, "MLPerf tiny benchmark," in *Advances in Neural Information Processing Systems Datasets and Benchmarks*, 2021.

[7] E. Liberis and N. D. Lane, "μNAS: Constrained neural architecture search for microcontrollers," *Proceedings of Machine Learning and Systems*, vol. 3, pp. 239–255, 2022.

[8] J. Lin, H. Cai, L. Zhu, and S. Han, "On-device training under 256kb memory," *Advances in Neural Information Processing Systems*, vol. 35, pp. 22 168–22 181, 2022.

[9] T. L. Hayes and C. Kanan, "Online continual learning for embedded devices," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2022.

[10] T. Mensink, J. Verbeek, F. Perronnin, and G. Csurka, "Distance-based image classification: Generalizing to new classes at near-zero cost," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 11, pp. 2624–2637, 2013.

[11] N. Ravi, N. Dandekar, P. Mysore, and M. L. Littman, "Activity recognition from accelerometer data," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 5, no. 1119–1125, 2005.

[12] G. I. Parisi, R. Kemker, J. L. Part, C. Kanan, and S. Wermter, "Continual lifelong learning with neural networks: A review," *Neural Networks*, vol. 113, pp. 54–71, 2019.

[13] B. P. Welford, "Note on a method for calculating corrected sums of squares and products," *Technometrics*, vol. 4, no. 3, pp. 419–420, 1962.

[14] J. J. Labrosse, *μC/OS-III: The Real-Time Kernel*. Micrium Press, 2011.

[15] Espressif Systems, "ESP32 technical reference manual v5.3," https://www.espressif.com/sites/default/files/documentation/esp32_technical_reference_manual_en.pdf, 2023.

[16] D. Anguita, A. Ghio, L. Oneto, X. Parra, and J. L. Reyes-Ortiz, "A public domain dataset for human activity recognition using smartphones," in *Proceedings of the European Symposium on Artificial Neural Networks (ESANN)*, 2013, pp. 437–442.